


SYSTEM INITIALIZATION / MODULE 01

Fundamentos de Data Science

El ciclo de vida del dato estructurado como un sistema operativo.



CORE CONCEPT / SUPERVISED LEARNING

El Motor Supervisado

El modelo aprende de un historial estructurado para predecir el futuro.




Matriz de Decisión: El Objetivo Predictivo

TARGET VARIABLE / CATEGORICAL

Clasificación

Predice a qué grupo pertenece un dato.



Spam vs. No Spam / Cliente abandona vs. Retiene.

TARGET VARIABLE / CONTINUOUS


Regresión

Estima un valor numérico continuo.




Precio de una casa / Gasto futuro de un cliente.

Limpieza: El Filtro de Entrada



Traducción Numérica


Las máquinas procesan distancias, no conceptos.



Variables Categóricas

One-Hot Encoding


Convierte texto (ej. Rojo, Azul) en columnas binarias independientes (Color_Rojo: 1, Color_Azul: 0).



Variables Numéricas

StandardScaler

Estandariza escalas dispares (ej. 1 a 1,000,000) a una media de 0 y desviación de 1.




Outliers (Valores Extremos)

Capping / Winsorization

Limita valores atípicos a un percentil máximo razonable sin destruir la fila de datos.

Pipelines y Contención de Datos




Data Leakage: Ocurre cuando el modelo “ve” información del conjunto de prueba durante el entrenamiento. Los Pipelines previenen esto.

Módulos Algorítmicos




Regresión Logística



Árboles de Decisión



Random Forest




Regresión Lineal



Regresión Logística

Rápido, interpretable. Ideal como baseline.




Árboles de Decisión

Intuitivo y visual. Riesgo: Alta tendencia al sobreajuste (overfitting).



Random Forest

Ensamble de múltiples árboles.
Robusto ante outliers, alta precisión.
Permite analizar la importancia de las variables.



Regresión Lineal

El modelo base para predecir valores continuos.

Panel de Evaluación: Clasificación

Precision

¿Cuántos positivos predichos fueron reales?

Recall

¿Cuántos positivos reales logró detectar?

F1-Score

El balance perfecto entre Precision y Recall.

Matriz de Confusión

 True Positives	 False Positives
 False Negatives	 True Negatives

Curva ROC

AUC cercano a 1 = Modelo Excelente



Panel de Evaluación: Regresión

Metrics Panel

MAE

Error promedio en unidades reales (ej. pesos).

RMSE

Penaliza fuertemente los errores grandes.

R^2

Proporción de variabilidad explicada (cercano a 1 es ideal).

Diagnostic Interface





Gráfico de Residuos


Si hay un patrón (ej. embudo), el modelo falla.



Histograma de Residuos

Los errores deben distribuirse simétricamente (distribución normal).

El Artefacto Completo



Un sistema cerrado, reproducible e iterativo.